

Análise Comparativa de Algoritmos para Alinhamento de Sequências de DNA: Programação Dinâmica vs. Abordagem Gulosa

Rafael Passos Domingues¹, Wagner Donizete Gonçalves¹

¹ Departamento de Ciência da Computação – Universidade Federal de Alfenas (UNIFAL-MG)
Avenida Jovino Fernandes de Sales 2600 – CEP 37133-840 – Alfenas – MG – Brasil

rafael.domingues@sou.unifal-mg.edu.br, wagner.goncalves@sou.unifal-mg.edu.br

Resumo. *Este trabalho apresenta uma análise comparativa entre duas abordagens algorítmicas aplicadas ao problema de alinhamento global de sequências de DNA: a Programação Dinâmica (baseada no algoritmo de Needleman-Wunsch) e uma heurística Gulosa. O sistema de pontuação adotado modela fielmente a complementaridade biológica das bases nitrogenadas, onde um match verdadeiro exige os pares Adenina-Timina ou Citosina-Guanina. Os resultados experimentais evidenciam o clássico trade-off entre precisão e eficiência computacional. Enquanto a Programação Dinâmica garante a otimalidade global com custo quadrático $O(N \times M)$, o algoritmo Guloso opera em tempo linear $O(N)$, porém com perda significativa de qualidade no alinhamento. A análise de desempenho revela que, para sequências superiores a 10.000 bases, a solução exata torna-se proibitiva devido a limitações de memória RAM e cache misses, justificando a adoção de heurísticas em aplicações de bioinformática em larga escala.*

1. Introdução

Desde a elucidação da estrutura em dupla hélice do DNA por [Watson e Crick 1953], o alinhamento de sequências genéticas tornou-se uma ferramenta fundamental na bioinformática. O DNA pode ser interpretado como a linguagem de programação mais antiga do planeta: um código quaternário composto pelas bases nitrogenadas Adenina (A), Timina (T), Citosina (C) e Guanina (G). Diferentemente de uma comparação textual convencional, onde letras iguais indicam correspondência, o pareamento do DNA obedece a regras bioquímicas estritas de complementaridade: a Adenina liga-se exclusivamente à Timina (A-T), e a Citosina à Guanina (C-G), formando pontes de hidrogênio estáveis.

O problema do alinhamento global consiste em encontrar a melhor sobreposição entre duas cadeias, inserindo espaços (*gaps*) quando necessário, de modo a maximizar uma função de pontuação que reflita a probabilidade evolutiva daquele alinhamento. Computacionalmente, isso se traduz em um problema de otimização combinatória com vasto espaço de busca.

Neste projeto, implementamos e comparamos dois paradigmas algorítmicos distintos:

- **Programação Dinâmica (PD):** Baseada no algoritmo de [Needleman e Wunsch 1970], garante a solução ótima global ao custo de maior consumo de tempo e memória.

- **Algoritmo Guloso (Heurística):** Toma decisões locais e imediatistas, priorizando a velocidade de execução em detrimento da garantia de otimalidade.

O foco deste trabalho não se limita à corretude matemática dos algoritmos, mas estende-se à análise de seu comportamento sob as restrições físicas do hardware, como latência de memória, fragmentação e *cache misses*, tópicos essenciais na engenharia de software de alto desempenho [Cormen et al. 2012, Ziviani 2007].

2. Metodologia

2.1. Sistema de Pontuação Biológico

A modelagem matemática do problema exige uma função de *score* que traduza a química molecular em valores numéricos. Diferente de algoritmos de comparação de *strings* que recompensam caracteres idênticos, nosso sistema segue rigorosamente os critérios de complementaridade de Watson e Crick. A Tabela 1 define os valores utilizados.

Tabela 1. Função de Avaliação Baseada em Complementaridade Biológica

Tipo de Alinhamento	Exemplo	Pontuação
<i>Match</i> (Par Complementar)	A-T, C-G	+2
<i>Mismatch</i> (Não Complementar)	A-A, A-C, T-G	-1
<i>Gap</i> (Inserção/Deleção)	A-, -C	-2

Justificativa Biológica:

- **Match (+2):** Representa a conservação evolutiva. A recompensa é alta porque o encaixe químico perfeito preserva a função da proteína codificada.
- **Mismatch (-1):** Corresponde a uma mutação pontual (substituição). Embora possa alterar a estrutura proteica, a célula frequentemente tolera esses erros. A penalidade é moderada.
- **Gap (-2):** Simula uma mutação do tipo *indel* (inserção ou deleção). Quando uma base é removida ou adicionada, toda a matriz de leitura do código genético (que é lido em tríades) se desloca (*frameshift*), geralmente resultando em uma proteína não funcional. Por isso, a penalidade é severa.

Note que, em nossa implementação, a igualdade entre caracteres (ex.: 'A' com 'A') é tratada como *mismatch* e penalizada com -1, pois a natureza não recompensa a igualdade, mas sim a complementaridade.

2.2. Programação Dinâmica (Needleman-Wunsch)

A Programação Dinâmica resolve o problema dividindo-o em subproblemas menores e armazenando os resultados intermediários. Construímos uma matriz de dimensão $(N + 1) \times (M + 1)$, onde N e M são os comprimentos das sequências. Cada célula (i, j) armazena a pontuação máxima do alinhamento parcial entre os primeiros i caracteres da sequência 1 e os primeiros j caracteres da sequência 2.

O preenchimento segue a recorrência:

$$M[i][j] = \max \begin{cases} M[i-1][j-1] + \text{score}(S_1[i], S_2[j]) & \text{(alinhar diagonal)} \\ M[i-1][j] + \text{gap_penalty} & \text{(gap na sequência 2)} \\ M[i][j-1] + \text{gap_penalty} & \text{(gap na sequência 1)} \end{cases}$$

Otimização de Engenharia de Software (Baixo Nível): Para otimizar o uso da hierarquia de memória e evitar *cache misses* frequentes, não utilizamos um array bidimensional tradicional. Em vez disso, alocamos um vetor unidimensional contíguo utilizando `malloc((N+1) * (M+1) * sizeof(int))`. O acesso à posição (i, j) é realizado através da aritmética de ponteiros `vetor[i * cols + j]`. Essa abordagem garante localidade espacial, pois os dados de uma mesma linha residem em endereços físicos adjacentes, maximizando a eficiência da cache do processador [Kernighan e Ritchie 1989].

A complexidade de tempo e espaço deste algoritmo é $O(N \times M)$. Embora garanta a solução ótima, sua viabilidade é limitada pelo hardware para sequências longas.

2.3. Algoritmo Guloso

Em contraste com a abordagem exaustiva da Programação Dinâmica, o algoritmo Guloso implementa uma heurística de decisão local. A cada passo, ele examina apenas os caracteres atuais e, no máximo, uma posição à frente (*lookahead* de profundidade 1).

A lógica de decisão é a seguinte:

1. Se os caracteres atuais são complementares (A-T ou C-G), alinha-os diretamente (ganho +2) e avança ambos os índices.
2. Caso contrário, o algoritmo verifica se inserir um *gap* em uma das sequências permitirá um *match* na posição seguinte.
3. Se nenhuma dessas opções for promissora, aceita-se o *mismatch* atual (penalidade -1).
4. Ao final do processamento, eventuais caracteres restantes são tratados como *gaps* forçados.

Essa estratégia evita a construção de matrizes e percorre as sequências de forma linear, resultando em complexidade de tempo $O(N + M)$. O consumo de memória é constante, utilizando apenas algumas variáveis escalares e ponteiros.

Contudo, por se basear em escolhas míopes (ótimo local), o algoritmo não possui garantia de convergência para a solução global ótima. Em muitos casos, o acúmulo de pequenas decisões subótimas leva a alinhamentos com pontuação significativamente inferior.

3. Resultados e Discussão

Os experimentos foram conduzidos em um ambiente controlado, com múltiplas execuções para cada tamanho de entrada, a fim de mitigar flutuações de desempenho do sistema operacional. A Tabela 2 apresenta a média das pontuações obtidas pelos dois algoritmos.

Análise da Qualidade: Observa-se que a Programação Dinâmica mantém pontuações consistentemente positivas e crescentes, refletindo sua capacidade de encontrar o alinhamento evolutivamente mais plausível. Por outro lado, o algoritmo Guloso frequentemente atinge escores negativos, indicando que as penalidades acumuladas superaram os acertos. Isso ocorre porque as decisões locais do Guloso, embora rápidas, carecem de uma visão global do contexto da sequência.

A Tabela 3 quantifica o custo computacional dessa precisão.

Tabela 2. Comparação da Qualidade do Alinhamento (Score Médio)

Tamanho da Sequência (N)	Score DP (Ótimo)	Score Guloso	Diferença Absoluta
100	35	-1	36
500	196	-44	240
1.000	408	-43	451
5.000	2.174	-179	2.353
10.000	4.443	-450	4.893

Tabela 3. Benchmarking de Desempenho (Tempo Médio em Segundos)

Tamanho (N)	Tempo DP (s)	Tempo Guloso (s)
1.000	0.025	0.001
5.000	0.501	0.005
10.000	2.004	0.010

A Programação Dinâmica exibe um crescimento quadrático no tempo de execução, conforme esperado pela complexidade $O(N \times M)$. O algoritmo Guloso, por sua vez, apresenta um crescimento linear quase imperceptível na escala do gráfico.

3.1. Análise Gráfica e o Limite do Hardware

A Figura 1 consolida visualmente o *trade-off* entre desempenho e consumo de memória.




Figura 1. Comparativo de Desempenho: Tempo de Execução e Consumo de Memória

O gráfico de tempo (esquerda) evidencia a trajetória parabólica da Programação Dinâmica, que rapidamente se distancia do eixo horizontal. O gráfico de memória (direita, em escala logarítmica) revela o verdadeiro gargalo: a alocação da matriz de Programação Dinâmica consome toda a memória RAM disponível para sequências acima de 10.000 bases.

O Contexto do Genoma Real: Para dimensionar a gravidade desse gargalo, considere as dimensões reais do código genético:

- **Vírus SARS-CoV-2:** ≈ 30.000 bases.

- **Bactéria *E. coli***: $\approx 4,6 \times 10^6$ bases.
- **Ser Humano (*Homo sapiens*)**: $\approx 3,2 \times 10^9$ bases.

Se a Programação Dinâmica já se mostra inviável para alinhar duas sequências de 10.000 caracteres (exigindo ≈ 100 milhões de células na matriz), a tentativa de alinhar dois genomas humanos demandaria uma matriz de aproximadamente 10^{19} células. Isso está ordens de grandeza além da capacidade de memória de qualquer supercomputador existente. É fisicamente impossível executar o algoritmo exato de Needleman-Wunsch em escala genômica.

Essa constatação valida a existência e a importância de algoritmos heurísticos como o Guloso. Embora ele não encontre o alinhamento perfeito definido por Watson e Crick em todos os detalhes, ele fornece uma resposta “boa o suficiente” em tempo hábil, permitindo que a pesquisa biológica avance dentro das limitações do hardware atual.

4. Divisão de Tarefas

- **Equipe Alpha (Rafael e Wagner)**: Projeto arquitetural do código em C, implementação das otimizações de memória contígua e análise de *cache misses*.
- **Equipe Bravo (Terceiro e Quarto)**: Geração de instâncias de teste, coleta de dados em CSV e execução dos benchmarks de tempo.
- **Equipe Charlie (Quinto e Sexto)**: Análise estatística dos resultados, elaboração dos gráficos e redação do presente relatório.

5. Conclusões

Este trabalho demonstrou empiricamente o *trade-off* inerente ao projeto de algoritmos para alinhamento de sequências biológicas. A Programação Dinâmica oferece a solução ótima global, mas seu custo computacional $O(N \times M)$ a torna inaplicável para problemas de escala genômica devido a limitações físicas de memória e tempo. Em contrapartida, o Algoritmo Guloso, com complexidade linear $O(N)$, sacrifica a garantia de otimalidade para viabilizar a execução em grandes volumes de dados.

A principal contribuição deste estudo para a formação em Ciência da Computação é a percepção de que a teoria algorítmica não pode ser dissociada das restrições da arquitetura de computadores. A otimização de baixo nível (como a alocação contígua de memória) e a compreensão do comportamento da cache são tão cruciais quanto a correte matemática do algoritmo.

Em um cenário futuro onde a computação quântica ou novas arquiteturas de memória superem essas barreiras, a lógica fundamental do alinhamento de sequências – os *matches*, *mismatches* e *gaps* definidos por Watson e Crick – permanecerá a mesma. Até lá, a bioinformática continuará a depender do equilíbrio inteligente entre a precisão da Programação Dinâmica e a velocidade das heurísticas.

Referências

- Watson, J. D. and Crick, F. H. C. (1953). Molecular structure of nucleic acids: a structure for deoxyribose nucleic acid. *Nature*, 171(4356):737–738.
- Needleman, S. B. and Wunsch, C. D. (1970). A general method applicable to the search for similarities in the amino acid sequence of two proteins. *Journal of Molecular Biology*, 48(3):443–453.

- Tarjan, R. E. (1983). *Data Structures and Network Algorithms*. CBMS-NSF Regional Conference Series in Applied Mathematics. SIAM, Philadelphia, PA.
- Kernighan, B. W. and Ritchie, D. M. (1989). *C: a linguagem de programação*. Campus, Rio de Janeiro, 2nd edition.
- Sedgewick, R. (2000). *Algorithms in C Part 5: Graph Algorithms*. Addison-Wesley, 3rd edition.
- Ziviani, N. (2007). *Projeto e Algoritmos com implementações em Java e C++*. Editora Thomson, São Paulo.
- Cormen, T. H., Leiserson, C. E., Rivest, R. L., and Stein, C. (2012). *Algoritmos: teoria e prática*. Elsevier, Rio de Janeiro, 3rd edition.