

Políticas de Escalonamento de Filas M/M/1: Uma abordagem multimetodológica

Rafael Passos DOMINGUES¹, Pedro Henrique Borges LUIZ¹

¹ *Instituto de Ciências Exatas, Universidade Federal de Alfenas (UNIFAL-MG), Brasil*
e-mail: rafael.domingues@sou.unifal-mg.edu.br, pedro.luiiz@sou.unifal-mg.edu.br

Abstract. Este trabalho apresenta uma análise multimetodológica abrangente de políticas de escalonamento em sistemas de filas M/M/1 com múltiplas classes de prioridade, integrando simulação de eventos discretos e técnicas de aprendizado de máquina não supervisionado. Desenvolvemos um *framework* experimental para avaliar três paradigmas de decisão: Round Robin (estática/agnóstica), Waiting Time Priority (reativa/gulosa) e Salles Utility (proativa/adaptativa). As simulações, conduzidas em cenários de carga variando de alta ($\rho = 0.900$) a crítica ($\rho = 0.999$) com mais de 380 mil amostras, revelaram o colapso das estratégias clássicas sob saturação. Os resultados demonstram a superioridade da abordagem baseada em utilidade, que alcançou reduções de aproximadamente **31%** na ocupação total do sistema (L_{sys}) e no tempo médio de espera (W_{sys}), além de mitigar a variabilidade das filas em cerca de **30%** comparado ao baseline. A análise de aprendizado de máquina corroborou a eficácia da política proposta ao identificar regimes distintos de congestionamento, validando a ocupação e a taxa de chegada como preditores críticos para a manutenção da estabilidade dinâmica do sistema.

Key words: Análise de Desempenho, Simulação de Eventos Discretos, Sistemas de Filas M/M/1, Escalonamento Baseado em Utilidade, Metadados em Tempo Real, Aprendizado de Máquina.

1. Introdução

A teoria de filas estocásticas fornece a base matemática para analisar sistemas que dependem de recursos compartilhados, incluindo plataformas de computação em nuvem, redes de telecomunicações 5G e ambientes industriais da Indústria 4.0. Modelos clássicos como o M/M/1 continuam úteis para compreender mecanismos essenciais de congestionamento, porém a complexidade dos sistemas atuais exige estudar configurações com múltiplos servidores e políticas de escalonamento mais expressivas.

Ao passar para sistemas M/M/c surge um problema central: como distribuir a capacidade de serviço entre fluxos concorrentes de forma eficiente e estável. Esse desafio se relaciona diretamente com temas de decisão sob incerteza e otimização de sistemas dinâmicos. Políticas amplamente utilizadas, como Round Robin, priorizam uniformidade, mas tendem a degradar sob alta carga. Por outro lado,

estratégias baseadas em prioridade, como Waiting Time Priority, respondem rapidamente a variações individuais, embora possam gerar efeitos colaterais que prejudicam o desempenho global.

Avanços recentes indicam que a integração de metadados operacionais em tempo real pode ampliar a eficácia das decisões de escalonamento. Abordagens guiadas por funções de utilidade representam esse movimento, já que permitem que o sistema adapte suas escolhas conforme o estado observado. Apesar do potencial teórico, ainda são raras as análises sistemáticas que avaliam essas políticas em modelos multi-servidor sob condições realistas de carga.

Este trabalho contribui dentro desse cenário por meio de quatro eixos complementares. O primeiro é a implementação de um framework M/M/1 com coleta estruturada de metadados. O segundo é o desenvolvimento de uma política Utility-Based fundamentada em janelas dinâmicas de observação. O terceiro é a comparação detalhada entre políticas estáticas, heurísticas e adaptativas usando simulação, formulação analítica e aprendizado de máquina. O quarto é a avaliação em regimes de saturação, com foco no comportamento quando a carga se aproxima do limite de estabilidade.

As contribuições obtidas abrangem frentes empíricas, metodológicas, teóricas e práticas. Demonstramos que políticas adaptativas podem superar abordagens estáticas em cenários críticos. Apresentamos um ambiente experimental integrado capaz de avaliar diferentes estratégias de escalonamento com consistência. Validamos princípios de escalonamento baseado em utilidade por meio de análise estatística rigorosa. Por fim, oferecemos evidências aplicáveis ao projeto de sistemas de missão crítica sujeitos a forte variabilidade.

A Seção 2 descreve a metodologia e as políticas analisadas. A Seção 3 apresenta os resultados quantitativos. A Seção 4 discute suas implicações conceituais e operacionais. A Seção 5 conclui com perspectivas para pesquisas futuras.

2. Metodologia

2.1. Políticas de Descarte Implementadas

As políticas de descarte implementadas no simulador de três filas M/M/1 podem ser categorizadas em estáticas e dinâmicas, baseadas no nível de consciência do estado do sistema.

2.1.1. Round Robin (RR) - Política Estática

O Round Robin implementa um algoritmo cíclico determinístico para alocação de clientes. Em um sistema de $K = 3$ filas, a próxima fila a ser considerada para descarte/alocação é dada por:

$$\text{Próxima Fila} = (i_{\text{atual}} + 1) \mod 3 \quad (1)$$

Esta política serve como baseline, representando abordagens que ignoram completamente o estado do sistema. Como demonstrado na análise de simulação, o RR resulta em um desempenho significativamente inferior (maior $E[N]$) em comparação com as políticas dinâmicas, especialmente em cenários de alta ocupação (ρ).

2.1.2. MAX_AVG_WAIT (MAW) - Política Gulosa Baseada em Tempo de Espera

A política MAX_AVG_WAIT (MAW), também referida em alguns contextos como Waiting Time Priority (WTP), é uma política gulosa que seleciona a fila com o pacote mais antigo, visando a equidade e a minimização do tempo de espera máximo.

$$j^* = \arg \max_{j \in \{1,2,3\}} (t_{\text{atual}} - t_{\text{chegada}}^{\text{cabeça}}) \quad (2)$$

Esta política otimiza métricas individuais (tempo de espera do cliente mais antigo) e, como visto nos resultados, leva a um desempenho sistêmico robusto, aproximando-se do limite teórico de um sistema M/M/1.

2.1.3. SALLES_UTILITY (SU) - Política Adaptativa com Metadados

A política SALLES_UTILITY (SU) implementa uma função de utilidade baseada em metadados para estimar o tempo médio de espera de cada fila, atacando proativamente o gargalo mais crítico. A política seleciona a fila com a maior utilidade (maior tempo de espera estimado): $j^* = \arg \max E[W]_j$.

A estimativa do tempo médio de espera ($E[W]_j$) é dada por:

$$E[W]_j = \frac{1}{T_j} \times (n_j \cdot t - S_j + D_j) \quad (3)$$

onde:

- S_j : Soma dos tempos de chegada na fila j
- D_j : Soma dos tempos de espera servidos na janela
- T_j : Total de pacotes servidos na janela
- n_j : Comprimento atual da fila j

O desempenho da SU foi estatisticamente indistinguível da MAW em termos de $E[N]$, sugerindo que ambas as heurísticas atingem um desempenho próximo ao ideal de balanceamento de carga.

2.2. Expressões Analíticas e Aproximações

Para sistemas de filas com políticas dinâmicas de descarte, expressões analíticas de forma fechada para $E[N]$ e $E[W]$ são complexas. No entanto, o desempenho das

políticas pode ser comparado com o limite inferior teórico de um sistema M/M/K (onde $K = 3$ filas).

- **RR (Aproximação Estática):** O desempenho do RR se aproxima de K filas M/M/1 independentes, cada uma com $\lambda_i = \Lambda/K$.

$$E[N]_{RR} \approx K \cdot \frac{\rho_{RR}}{1 - \rho_{RR}} = \frac{\Lambda}{\mu - \frac{\Lambda}{K}}$$

- **MAW e SU (Aproximação Dinâmica Ideal):** O desempenho destas políticas dinâmicas se aproxima do limite teórico de um sistema M/M/k.

$$E[N]_{MAW/SU} \approx E[N]_{MMK}$$

2.3. Metodologia de Análise

2.3.1. Detecção de Estado Estacionário

Para garantir a validade da análise estatística, o viés transiente inicial foi removido. O estado estacionário foi considerado alcançado quando a variação relativa entre janelas de 100 amostras caiu abaixo de 2%:

$$\Delta_{\text{rel}} = \frac{|\mu_i - \mu_{i-1}|}{\mu_{i-1}} < 0.02 \quad (4)$$

Conforme a Tabela 1, este procedimento removeu aproximadamente 15% dos dados iniciais de cada simulação.

2.3.2. Modelagem e Validação

Ajustamos modelos polinomiais para capturar relações não-lineares entre a carga (ρ) e o desempenho ($E[N]$), validando-os através do coeficiente de determinação R^2 .

$$E[N] = \beta_0 + \beta_1\rho + \beta_2\rho^2 + \beta_3\rho^3 \quad (5)$$

Aproximações teóricas adicionais foram utilizadas para descrever o comportamento em cenários específicos:

$$E[N]_{\text{Aging}} \approx \frac{\rho}{1 - \rho^3} \cdot \beta_{\text{buffer}} \quad \text{para } \rho \rightarrow 1 \quad (6)$$

$$E[N]_{C\mu} \approx K + \frac{\rho_{\text{prioritaria}}}{1 - \rho_{\text{prioritaria}}} \quad (\text{Crescimento Linear Suave}) \quad (7)$$

2.3.3. Abordagem Integrada de Análise

Implementamos uma abordagem integrada para a análise dos dados:

- **Análise Estatística:** ANOVA de dois fatores (Política e ρ) e testes post-hoc (Tukey HSD) confirmaram que o RR é significativamente pior, enquanto MAW e SU são estatisticamente equivalentes em termos de $E[N]$.
- **PCA:** Redução de dimensionalidade, com 92.98% da variância explicada pelas componentes principais.
- **K-means:** Clusterização com seleção ótima (2 clusters) via silhouette score (0.472), separando claramente o desempenho do RR das políticas dinâmicas.
- **Random Forest:** Regressão ($R^2 = 0.9996$) e classificação ($R^2 = 0.9992$) com análise de importância de features, destacando que as métricas de fila individual (λ_i , $E[N]_i$) são os principais fatores de distinção entre as políticas.

3. Resultados da Simulação

Nesta secção, apresentamos a avaliação de desempenho das três políticas de descarte de pacotes (*Round Robin*, *Max Avg Wait* e *Salles Utility*) num sistema de três filas M/M/1. A análise considera dois cenários de intensidade de tráfego: alta carga ($\rho = 0.900$) e saturação crítica ($\rho = 0.999$).

3.1. Análise Estatística Descritiva

A Tabela 1 resume as métricas de ocupação total do sistema (L_{sys}) obtidas via Lei de Little simulada. Observa-se que, para $\rho = 0.900$, todas as políticas mantêm o sistema estável com médias próximas (diferença $< 4\%$). No entanto, no cenário de saturação ($\rho = 0.999$), a divergência de desempenho torna-se evidente.

A política *Salles Utility* demonstrou a maior robustez, mantendo uma ocupação média de ≈ 1.040 pacotes, o que representa uma redução de **31,1%** em comparação com o *Round Robin* e **21,2%** em comparação com o *Max Avg Wait*.

Tabela 1
Estatística Descritiva da Ocupação Total (L_{sys}) por Cenário

Cenário (ρ)	Política	Média (μ)	Desvio Padrão (σ)	Máximo
0.900	Round Robin	24.8	12.5	86
0.900	Max Avg Wait	23.9	11.8	82
0.900	Salles Utility	24.1	12.0	84
0.999	Round Robin	1,510.5	850.2	3,000
0.999	Max Avg Wait	1,320.1	740.8	2,620
0.999	Salles Utility	1,040.3	590.5	2,062

3.2. Inferência Estatística e Teste de Hipótese

Para validar se as diferenças observadas no cenário crítico ($\rho = 0.999$) são estatisticamente significativas, aplicou-se o teste não-paramétrico de Kruskal-Wallis, visto que a distribuição das filas M/M/1 não segue uma normalidade.

As hipóteses testadas foram:

- H_0 : As medianas de ocupação das três políticas são iguais.
- H_1 : Pelo menos uma política difere das demais.

O teste resultou num valor-p de $p < 0.001$, rejeitando H_0 com nível de confiança de 99%. Isso confirma que a redução de fila proporcionada pela política *Salles Utility* não é fruto de aleatoriedade estocástica, mas sim de uma eficiência algorítmica superior na gestão de recursos escassos.

3.3. Caracterização de Regimes via Machine Learning

Utilizou-se o algoritmo de agrupamento *K-Means* ($k = 3$) para classificar os estados do sistema em três regimes operacionais baseados nos vetores de tamanho de fila $[q_0, q_1, q_2]$: (1) Fluxo Livre, (2) Transição e (3) Congestionamento Severo.

A análise de PCA cristaliza a complexidade de 380 mil amostras em uma visualização intuitiva da dinâmica do sistema. O formato em "V" da figura 1 revela uma verdade fundamental sobre o escalonamento de filas: sob baixas cargas (vértice inferior, cor roxa/azul escuro), todas as políticas convergem para um desempenho similar.




Figura 1. Mapeamento do espaço comportamental do sistema via Análise de Componentes Principais (PCA). Segregação espacial das políticas, destacando a trajetória distinta da abordagem Utility-Based (Salles Utility) e Round Robin em relação às heurísticas padrão.

No entanto, à medida que a carga aumenta drasticamente (regiões amarelas da figura 2), o sistema sofre uma bifurcação comportamental. O gráfico da esquerda demonstra que as políticas propostas (*Round Robin* & *Utility-Salles*) não se misturam aleatoriamente com a "nuvem" cinza das políticas ineficientes; elas ocupam trajetórias específicas e controladas dentro desse espaço de alta entropia. Isso valida visualmente que a "inteligência" da política baseada em utilidade efetivamente altera o regime de operação do sistema, mantendo-o em uma subregião do espaço de estados que minimiza o atraso, mesmo quando submetido às condições extremas de carga mostradas no gráfico da figura 2.




Figura 2. Mapeamento do espaço comportamental do sistema via Análise de Componentes Principais (PCA). Distribuição do fator de carga, evidenciando a bifurcação dos estados do sistema conforme a saturação se aproxima do limite crítico ($\rho \approx 0.999$), em amarelo).

A análise dos clusters revela que a política *Round Robin* permaneceu em estado de congestionamento severo durante aproximadamente 65% do tempo de simulação, enquanto a *Salles Utility* reduziu esse tempo para 42%, demonstrando maior capacidade de recuperação (*recovery rate*) após picos de chegada (λ).

4. Conclusão Parcial

Os resultados indicam que, para sistemas operando próximos da capacidade máxima teórica ($\rho \rightarrow 1$), políticas agnósticas ao estado da fila (como *Round Robin*) degradam rapidamente. A introdução de uma função de utilidade (*Salles Utility*) permitiu um ganho de performance da ordem de 30% na métrica de ocupação, sem comprometer a equidade entre as classes de serviço.

5. Discussão e Interpretação Teórica

5.1. Performance Relativa e Transição de Fase

A Tabela ?? revela o padrão central deste estudo: a existência de uma transição de fase no comportamento do sistema. Em cargas moderadas a altas ($\rho = 0.900$), o sistema opera em uma região linear onde a capacidade de serviço (μ) é suficiente para absorver flutuações estocásticas. Neste regime, as diferenças entre as políticas são estatisticamente marginais, com a *Utility-Based* apresentando desempenho comparável à *Round Robin*.

A divergência crítica emerge quando o sistema entra em regime de saturação assintótica ($\rho \rightarrow 1$). Em $\rho = 0.999$, observamos que políticas agnósticas (RR) e puramente reativas (WTP) falham em conter o crescimento exponencial das filas. Contrastando com os resultados preliminares, a política *Utility-Based* demonstrou uma superioridade robusta, alcançando uma redução de aproximadamente **31%** na ocupação total e no tempo médio de espera.

Teoricamente, isto ocorre porque a função de utilidade (Eq. 3) incorpora o produto $L_j \cdot \Delta t$, agindo como um preditor de "custo futuro". Enquanto a política WTP olha para o passado (quem esperou mais), a *Utility-Based* olha para o impacto sistêmico, prevenindo que filas volumosas bloqueiem o servidor (*Head-of-Line Blocking* virtual) por períodos excessivos.

5.2. Análise de Estabilidade e Previsibilidade (QoS)

A previsibilidade é, frequentemente, mais crítica que a velocidade bruta em sistemas de tempo real. A Tabela ?? demonstra que a política proposta não apenas reduz a média, mas comprime a dispersão dos dados.

Observou-se uma redução no desvio padrão de $\sigma \approx 850$ (RR) para $\sigma \approx 590$ (Utility). Em termos de densidade de probabilidade (validada via KDE), isso se traduz em uma cauda "mais leve". A política adaptativa reduz drasticamente a probabilidade de eventos de latência extrema (outliers), o que é essencial para o cumprimento de Acordos de Nível de Serviço (SLA) rigorosos.

5.3. Interpretação dos Modelos de Aprendizado de Máquina

A fusão dos resultados de *Feature Importance* (Random Forest) com a Análise de Clusters (K-Means) fornece uma validação mecanicista para os resultados empíricos:

1. **Dominância dos Preditores:** O modelo confirmou que a Taxa de Chegada ($\approx 59\%$) e a Ocupação Instantânea ($\approx 25\%$) governam o estado do sistema.
2. **Gestão de Regimes:** A análise de clusters revelou que o sistema oscila entre "Fluxo Livre" e "Congestionamento Severo". A superioridade da política *Utility-Based* reside na sua capacidade de maximizar o tempo de permanência no regime de Fluxo Livre (Cluster 0).

Diferente do *Round Robin*, que distribui o tempo de serviço cegamente, a política de utilidade atua dinamicamente para "empurrar" o sistema de volta para estados de menor energia (menor ocupação) sempre que uma transição de regime é iminente.

5.4. Limitações e Validade Externa

Apesar da robustez dos resultados, reconhecemos limitações no escopo:

- **Natureza do Tráfego:** O uso de chegadas Poisson pressupõe independência entre eventos. Tráfegos reais de rede (internet/vídeo) frequentemente exibem auto-similaridade e caudas pesadas (distribuições de Pareto), o que poderia exacerbar as diferenças observadas.
- **Topologia:** O estudo limitou-se a um servidor único com múltiplas classes ($M/M/1/Priority$). Em arquiteturas de múltiplos servidores ($M/M/k$), a eficiência do *Work-Stealing* poderia alterar o ranking das políticas.

5.5. Refactor

Inicialmente, o ambiente de simulação foi limitado a três políticas elementares: *Round Robin [RR]*, *Waiting Time Priority [WTP]* e *Utility Based [Salles]*. Experimentos preliminares mostraram que essas heurísticas produziam resultados inconclusivos sob distribuições de cauda pesada. A ausência de percepção global do estado levava a dois desfechos binários: o sistema colapsava em um estado de travamento causado por bloqueio na cabeça da fila (HOL) ou apresentava variância incontrolável.

Para superar essas limitações e permitir controle estocástico avançado, o simulador passou por uma refatoração arquitetural ampla. Essa evolução introduz uma classe `SystemState` para fornecer contexto global e foi implementado uma classe *Markoviana Orquestradora* capaz de alternar políticas dinamicamente em tempo de execução com base na dinâmica das próprias matrizes de transição, populadas conforme as métricas são computadas.

5.6. Fase I: Refatoração Arquitetural

A transformação central envolveu uma mudança profunda na interface de políticas. O método legado `selectQueue`, que anteriormente recebia um vetor simples de filas da struct *Queue*, foi redefinido para receber uma referência constante ao `SystemState` global.

- **Contexto Global:** A estrutura `SystemState` permitiu encapsular a estimativa global da taxa de chegada ($\hat{\lambda}$), o tempo atual de simulação e o vetor de filas. Isso permitiu, dentre outras coisas, que as políticas tomassem decisões com base em tendências temporais em vez de depender somente dos comprimentos instantâneos das filas.

- **Atributos de Fila:** A classe `Queue` em `queue.hpp` foi ampliada com os atributos `weight` (`double`) e `utility_type`, possibilitando Round Robin Ponderado e roteamento baseado em utilidade.

Refatoramos o código, implementado em c, do simulador de eventos discretos, para C++, aplicando programação orientada a objetos com um módulo de análise em Python. O estado do sistema S_t foi monitorado continuamente. Comparamos quatro estratégias principais: *Aging*, *First In First Out (FIFO)*, *Round Robin* e *Shortest Queue (SQ)*. As seguintes métricas foram registradas: Ocupação Média (L), Latência de Cauda (P_{99}) e Erro de Violação da Lei de Little (E_{LL}). A figura 3 detalha o fluxo de execução e a organização estrutural do simulador desenvolvido para o experimento. Foi priorizado uma atômica separação de responsabilidades, onde o núcleo de simulação (Simulation Core, à direita) gerencia a dinâmica estocástica da fila M/M/1 e o ciclo de vida dos eventos, desacoplando-o da lógica de decisão. O diagrama evidencia como as diferentes políticas de escalonamento: Round Robin, Waiting Time Priority e Utility-Based, são encapsuladas como componentes intercambiáveis (na seção inferior/verde), conectadas através de uma interface de agendamento central. Essa arquitetura desacoplada é fundamental para a coleta das métricas de Little, pois permite a injeção controlada das diferentes políticas de descarte para os distintos cenários de carga crítica ($\rho \rightarrow 1.0$) sem alterar a integridade do motor de simulação, garantindo a consistência na coleta massiva de dados que alimenta a etapa posterior de aprendizado de máquina.




Figura 3. Diagrama esquemático da arquitetura modular do framework de simulação de eventos discretos.

5.7. Fase II: O Arsenal Tático

Para testar o sistema de forma rigorosa, ampliamos o conjunto de algoritmos para além dos conceitos tradicionais de sistemas operacionais:

1. **Política de Utilidade Salles:** Inspirada em Salles e Barria, essa política calcula a perda marginal de utilidade $U(t)$ para pacotes na cabeça da fila, priorizando classes de tráfego de modo dinâmico.
2. **A Regra $c\mu$:** Implementação do padrão teórico de optimalidade, priorizando filas com o maior produto entre custo e taxa de serviço ($c \cdot \mu$).

3. **Weighted Round Robin (WRR):** Mecanismo robusto que utiliza contadores de quantum para evitar inanição, solucionando o problema análogo ao do Jantar dos Filósofos observado em escalonadores com prioridade estrita.
4. **Índice de Whittle:** Política investigativa que trata filas como Bandits Inquietos, calculando um índice associado à optimalidade assintótica.

5.8. Fase III: O Orquestrador Markoviano

A inovação mais significativa é a `MarkovSwitchingPolicy`. Essa meta-política resolve o desafio de integrar o desempenho do C++ com o aprendizado produzido em Python.

- **Discretização:** Implementa a função `discretizeState`, que mapeia métricas contínuas do sistema para identificadores de estado finitos.
- **Carregamento da Matriz:** Carrega uma Matriz de Probabilidades de Transição a partir de um arquivo CSV gerado pelo backend em Python. Isso permite que o sistema altere sua subpolítica ativa, como trocar de SQ para WRR, de acordo com o estado de congestão atual.

5.9. Fase IV: Análise e Verificação

Para validar essas interações complexas, o framework de análise foi aprimorado:

- **Análise Residual** Um novo módulo (`residuals.py`) foi criado para calcular os resíduos da Lei de Little ($R = L - \lambda W$).
- **Análise de Rastros:** O sistema de registro em `simulator.cpp` foi atualizado para registrar `system_state_id` e `active_policy`, permitindo reconstruir a trajetória completa das decisões.

Essa estratégia de implementação garante que os resultados apresentados na seção seguinte não sejam meros artefatos de uma simulação, mas produtos de um sistema de controle robusto e sensível ao estado.

6. Resultados e Discussão

O gráfico da figura 4 demonstra visualmente o impacto das políticas de escalonamento na estabilidade do sistema sob carga extrema. Observa-se uma clara bifurcação no comportamento das filas: enquanto um grupo de políticas (incluindo *Strict Priority & Aging*) satura rapidamente o sistema, atingindo o teto de capacidade (observado na linha constante em 3000, indicando lotação do buffer), as políticas analisadas no estudo, especificamente a *Round Robin* e a *Salles Utility (Utility-Based)*, demonstram maior resiliência. Estas últimas conseguem manter a ocupação total em um equilíbrio dinâmico (oscilando entre 2000 e 2500), evitando o colapso total da fila. Isso corrobora os resultados estatísticos que apontam a

redução de $E[N]$ pela política *Utility-Based*, provando sua capacidade de gerenciar o congestionamento e evitar o bufferbloat mesmo quando a demanda beira a capacidade máxima de serviço.




Figura 4. Evolução temporal da ocupação total do sistema (N) sob regime de saturação crítica ($\rho \approx 0.999$), comparando a estabilidade de diferentes políticas de escalonamento.

A análise da evolução do *Queue Imbalance* revela como as políticas gerenciam a equidade (fairness) na distribuição de recursos quando o sistema opera no limite de sua capacidade. O gráfico da figura 5 evidencia uma dicotomia de comportamento: enquanto políticas baseadas em heurísticas rígidas ou prioridades estritas (linhas oscilantes no topo e meio do gráfico) sofrem com alta volatilidade, indicando que certos fluxos estão sendo privilegiados em detrimento de outros (gerando inanição), as políticas *Round Robin* & *Utility-Based* (*Salles Utility*) mantêm-se consistentes na linha de base (próximo a 0.0). Este resultado é crucial para validar a política adaptativa: ele demonstra que a redução de 20% no tempo de espera $E[W]$, citada no contexto geral, não é obtida sacrificando a equidade. A abordagem baseada em utilidade consegue manter o balanceamento de carga tão estável quanto o *Round Robin*, mas com a inteligência necessária para otimizar o fluxo global.




Figura 5. Dinâmica temporal do desequilíbrio entre filas (*Queue Imbalance*) sob saturação extrema ($\rho \approx 0.999$), contrastando a estabilidade distributiva das políticas propostas versus abordagens convencionais.

Os gráficos de densidade da figura 6 ilustram o comportamento estocástico do sistema no limiar da instabilidade. A forma de platô observada nas distribuições, especialmente em $E[N]$ (canto superior esquerdo), indica uma alta entropia e

variabilidade: sob carga ($\rho \rightarrow 0.999$), as filas transitam por quase todos os estados de ocupação possíveis, evidenciando a dificuldade de convergência para uma média estável (validada pela distribuição do Erro de Little). No entanto, a comparação entre as curvas revela a eficácia da política *Utility-Based (Salles Utility)*. Enquanto políticas convencionais apresentam uma distribuição uniforme ou desviada para a direita (maior ocupação), a abordagem baseada em utilidade demonstra uma tendência sutil de deslocamento da massa de probabilidade para regiões de menor ocupação e maior eficiência. Isso confirma estatisticamente que a redução de 20% nos valores médios não é um outlier, mas resultado de uma mudança consistente no perfil de distribuição de probabilidade dos estados do sistema.




Figura 6. Análise de densidade de probabilidade (KDE) das métricas de desempenho, Número no Sistema ($E[N]$), Erro da Lei de Little e Eficiência do Sistema sob regime de saturação extrema ($\rho \approx 0.999$).

A orquestração submeteu o sistema evoluído a cargas variando de $\rho = 0.800$ até $\rho = 0.999$ ao longo de um horizonte de simulação de 86400 segundos, e a figura 7 apresenta o mapa de fases de ocupação e o impacto entre as políticas de descarte.




Figura 7. **Mapa de Fases de Ocupação.** Heatmap que mostra a Ocupação Média do Sistema como função do Fator de Carga (ρ) e da Política de Balanceamento de Carga. Tons mais escuros indicam níveis maiores de congestão, evidenciando os pontos de ruptura de algoritmos estáticos em comparação com algoritmos dinâmicos.

A análise das correlações revela a estrutura latente dos dados que alimentaram o modelo de aprendizado de máquina. Destaca-se a forte correlação negativa ($r = -0.900$) entre *Queue Imbalance* & *Total Occupancy*, indicando que em cenários de saturação, o "alisamento" das filas é intrinsecamente ligado à ocupação total: à medida que o sistema enche, as políticas eficazes (como a *Utility-Based*) forçam um equilíbrio de carga para evitar o desperdício de capacidade. Crucialmente, a variável *arrivalRateEst* demonstra baixa correlação linear com as demais métricas de saída (predominância de tons claros na última linha/coluna). Isso valida estatisticamente sua importância de 59.07% no modelo de ML citada anteriormente: por ser "ortogonal"(independente) às variáveis de estado interno como $E[N]$, a estimativa da taxa de chegada fornece entropia única e não redundante para o algoritmo de decisão, tornando-se o discriminador crítico para a adaptação da política em tempo real.




Figura 8. Matriz de correlação entre as variáveis operacionais do sistema, evidenciando a interdependência entre métricas de estado (Ocupação, Imbalance) e desempenho (Eficiência, Erro de Little).

A Figura 9 apresenta o mapeamento de comportamento das políticas no espaço de características. O conjunto completo de 380 160 amostras, distribuído entre onze políticas e quatro regimes de carga, foi processado por meio de padronização estatística seguida da aplicação de *KMeans*. O resultado foi projetado em duas dimensões pelo algoritmo *t-SNE*, permitindo observar padrões globais que não seriam visíveis em métricas escalares tradicionais.

O objetivo desta etapa foi verificar se diferentes políticas de escalonamento ocupam regiões distintas do espaço comportamental. A hipótese central propõe que clusters bem definidos indicam famílias de estratégias com dinâmicas semelhantes, enquanto regiões sobrepostas sugerem políticas que respondem de modo equivalente às condições de carga.

Os resultados confirmam essa estrutura: as trajetórias de execução se agrupam em curvas coesas que refletem regimes operacionais estáveis. Políticas como *MAX_AVG_WAIT*, *ROUND_ROBIN* e *SALLES_UTILITY* formam grupos se-

parados, cada um associado a um padrão característico de oscilação, estabilidade temporal e variação da ocupação. Essa separação reforça a existência de uma taxonomia comportamental que vai além das métricas de desempenho usuais.

O impacto científico desta análise é direto. A estrutura dos clusters permite identificar políticas que apresentam comportamento anômalo, sugerir fusões de estratégias e guiar o desenvolvimento de heurísticas híbridas. A consistência geométrica dos agrupamentos indica que a evolução do sistema segue dinâmicas estruturadas e, portanto, previsíveis, justificando o uso de modelos de decisão sensíveis ao estado global do sistema.




Figura 9. **Behavioral Clustering.** Visualização t-SNE com agrupamento via KMeans para 380 160 amostras. Cada curva representa a trajetória projetada de uma política em múltiplos regimes de carga. A geometria dos clusters revela assinaturas comportamentais distintas entre as estratégias.

A visualização via *t-SNE* confirma a existência de regimes operacionais fundamentalmente distintos entre as políticas analisadas. Ao contrário de uma distribuição contínua ou caótica, a formação de trajetórias curvilíneas e clusters bem definidos (as "ilhas" separadas por cor) indica que cada família de algoritmos: Estática, Gulosa e Adaptativa, possui uma assinatura comportamental única no espaço de alta dimensionalidade. A clara segregação sugere que a política *Utility-Based* não oferece apenas uma melhoria incremental, mas opera sob uma lógica qualitativamente diferente, navegando pelo espaço de estados de uma forma que as heurísticas tradicionais não conseguem replicar. Isso valida a robustez do modelo de aprendizado de máquina, demonstrando que é possível classificar e distinguir

as estratégias de otimização baseando-se puramente nos padrões dos metadados de execução.

6.1. Validação: Residuais da Lei de Little

Para verificar a fidelidade da simulação, analisamos os residuais da Lei de Little, como mostrado na Figura ???. Os dados revelam um fenômeno contraintuitivo. Os agrupamentos de alta ocupação (região inferior direita, associados a políticas saturadas) exibem os menores erros de medição. Isso ocorre porque uma fila completamente preenchida se comporta como um sistema de fluxo contínuo de taxa constante, no qual vale aproximadamente $L \approx \lambda_{max}W$, o que reduz as flutuações estocásticas. Em contraste, os agrupamentos de baixa ocupação (lado esquerdo, associados à política *SQ*) apresentam maior variância de erro. Do ponto de vista científico, isso confirma que a implementação proposta de *SystemState* é robusta. Os erros observados não são falhas de software e sim artefatos estatísticos resultantes da medição de sistemas altamente dinâmicos em janelas temporais finitas. A convergência desses residuais sustenta o uso do *Markov Orchestrator* proposto para suavizar essas transições.

Tabela 2
Snapshot de Ocupação de Filas em Carga Crítica ($\rho = 0.999$)

Política	Fila 0 (q_0)	Fila 1 (q_1)	Fila 2 (q_2)	Total ($E[N]$)	Status do Sistema
AGING	1000	1000	999	2999	Colapso (Buffer Full)
LONGEST Q	998	998	999	2995	Saturação Balanceada
C-MU RULE	11	1000	1000	2011	Eficiente (Starvation $q_{1,2}$)

Nota: Capacidade máxima do buffer por fila estimada em 1000 pacotes.

Tabela 3
Validação da Simulação: Erro Relativo da Lei de Little ($|L - \lambda W|$)

Carga (ρ)	Política Ativa		
	AGING	C-MU RULE	LONGEST QUEUE
0.800	0.0001	0.0002	0.0001
0.900	0.0050	0.0120	0.0040
0.950	0.0200	0.0564	0.0250
0.999	0.0003	0.0169	0.0002

Tabela 4
Comparativo de Desempenho Multidimensional (Cenário $\rho = 0.90$)

Métrica	AGING	C-MU RULE	LONGEST QUEUE	Melhor Política
Ocupação Média ($E[N]$)	48.2	32.1	55.4	<i>C-Mu Rule</i>
Tempo de Espera ($E[W]$)	Médio	Mínimo	Alto	<i>C-Mu Rule</i>
Índice de Justiça (σ_{filas}^2)	15.4	850.2	0.1	<i>Longest Queue</i>
Estabilidade (Drift)	Alta	Média	Muito Alta	<i>Longest Queue</i>

7. Considerações Finais

Este trabalho demonstrou, através de uma análise multimetodológica, que em sistemas de filas com múltiplas classes de serviço, políticas de escalonamento adaptativas baseadas em utilidade (*Salles Utility*) superaram significativamente abordagens estáticas (*Round Robin*) e puramente gulosas (*Max Avg Wait*).

A análise quantitativa dos cenários evidenciou que a escolha da política de descarte é marginal em situações de baixa carga ($\rho = 0.900$), onde o sistema opera na região linear. Contudo, em regimes de saturação crítica ($\rho = 0.999$), a política baseada em utilidade provou ser determinante para a estabilidade do sistema. Os resultados experimentais indicaram uma redução de aproximadamente **31%** na ocupação total média (L_{sys}) e no tempo médio de espera (W_{sys}), superando a melhoria de 20% estimada inicialmente. Além disso, a variabilidade do sistema (medida pelo desvio padrão das filas) foi reduzida em cerca de **30%**, sugerindo uma maior previsibilidade na qualidade de serviço (QoS).

A comparação entre as heurísticas revelou limitações fundamentais nas abordagens clássicas. Enquanto a política *Round Robin* garante justiça no atendimento, ela falha em priorizar filas críticas, levando a um crescimento rápido da ocupação total. Por outro lado, a política *Max Avg Wait*, embora superior ao método cíclico, demonstrou sofrer de instabilidade em momentos de pico, comportando-se de maneira reativa. A política proposta (*Salles Utility*) mitigou esses efeitos ao ponderar o estado global do sistema, evitando que o bloqueio de uma fila específica degradasse a performance do servidor como um todo. Isso confirma que métricas compostas (utilidade) são mais robustas que métricas simples (apenas tempo ou apenas tamanho) para decisões de escalonamento.

A validação metodológica confirmou a coerência entre o escopo simulado e os resultados obtidos. As três políticas analisadas cobriram o espectro de estratégias de escalonamento (Cíclica, Gulosa e Baseada em Utilidade), permitindo uma caracterização completa dos regimes de carga. A coleta de métricas baseadas na Lei de Little, suportada por um volume robusto de amostras, garantiu intervalos de confiança estreitos e baixa variância residual, validando a significância estatística das diferenças observadas via testes de hipótese (Kruskal-Wallis). Ademais, a análise via aprendizado de máquina não supervisionado (*K-Means*) corroborou os dados brutos, identificando que a política de utilidade maximiza o tempo de

permanência do sistema em regimes de "fluxo livre", retardando a entrada em estados de congestionamento severo.

Conclui-se que estratégias adaptativas baseadas em metadados oferecem ganhos reais e mensuráveis em cenários críticos, generalizando-se bem para arquiteturas de filas paralelas. O estudo abre caminho para a implementação de escalonadores inteligentes em ambientes de alta demanda, onde a latência e a estabilidade são requisitos conflitantes.

Como trabalhos futuros, identificamos as seguintes direções promissoras:

- **Extensões do Modelo:** Investigação de sistemas com múltiplos servidores ($M/M/k$ com $k \geq 3$) para avaliar o impacto da política na eficiência do paralelismo.
- **Cenários Assimétricos:** Avaliar o desempenho sob cargas de chegada (λ) desbalanceadas entre as filas, simulando rajadas de tráfego específicas.
- **Aprendizado por Reforço:** Implementação de agentes de RL (*Reinforcement Learning*) que aprendam os pesos da função de utilidade dinamicamente.
- **Análise de Fairness:** Investigação formal do *trade-off* entre a eficiência global (redução de $E[W]$) e a justiça no atendimento entre as diferentes classes.

Os resultados aqui apresentados têm implicações diretas para o projeto de balanceadores de carga em *data centers*, escalonadores de pacotes em redes 5G e gerenciadores de tarefas em sistemas de tempo real crítico.

Referências

- [1] Kleinrock, L. *Queueing Systems, Volume I: Theory*. Wiley-Interscience, 1975.
- [2] Salles, R. M. e Barria, J. A. "Utility-Based Scheduling Disciplines for Adaptive Applications Over the Internet". *IEEE Communications Letters*, 6(5):217-219, 2002.
- [3] Law, A. M. *Simulation Modeling and Analysis*. 4ª edição, McGraw-Hill, 2007.
- [4] Cooper, R. B. *Introduction to Queueing Theory*. 2ª edição, North Holland, 1981.
- [5] Trivedi, Kishor S. *Probability and Statistics with Reliability, Queuing, and Computer Science Applications*, 1946.