

Políticas de Escalonamento em Filas M/M/3: Uma Abordagem Multimetodológica

Rafael Passos DOMINGUES¹, Pedro Henrique Borges LUIZ¹

¹ *Instituto de Ciências Exatas, Universidade Federal de Alfenas (UNIFAL-MG), Brasil*
e-mail: rafael.domingues@sou.unifal-mg.edu.br, pedro.luiiz@sou.unifal-mg.edu.br

Abstract. Este trabalho apresenta uma análise multimetodológica abrangente de políticas de escalonamento em sistemas de filas M/M/1, integrando simulação de eventos discretos, modelagem analítica e técnicas de aprendizado de máquina. Desenvolvemos um framework experimental que implementa três políticas distintas: Round Robin (estática), Waiting Time Priority (gulosa) e Utility-Based (adaptativa com metadados). As simulações foram conduzidas em quatro cenários de carga crítica ($\rho = 0.800, 0.900, 0.950, 0.999$) com mais de 380 mil amostras coletadas. Os resultados demonstram que a política Utility-Based alcança reduções significativas de até 20% no tempo médio de espera ($E[W]$) e número médio no sistema ($E[N]$) em regimes de saturação extrema ($\rho = 0.999$). A análise de aprendizado de máquina identificou a taxa de chegada (59.07%) e ocupação (24.93%) como preditores dominantes, validando estatisticamente a abordagem baseada em metadados.

Key words: Análise de Desempenho, Simulação de Eventos Discretos, Sistemas de Filas M/M/1, Escalonamento Baseado em Utilidade, Metadados em Tempo Real, Aprendizado de Máquina Aplicado.

1. Introdução

A teoria de filas estocásticas fornece a base matemática para analisar sistemas que dependem de recursos compartilhados, incluindo plataformas de computação em nuvem, redes de telecomunicações 5G e ambientes industriais da Indústria 4.0. Modelos clássicos como o M/M/1 continuam úteis para compreender mecanismos essenciais de congestionamento, porém a complexidade dos sistemas atuais exige estudar configurações com múltiplos servidores e políticas de escalonamento mais expressivas.

Ao passar para sistemas M/M/c surge um problema central: como distribuir a capacidade de serviço entre fluxos concorrentes de forma eficiente e estável. Esse desafio se relaciona diretamente com temas de decisão sob incerteza e otimização de sistemas dinâmicos. Políticas amplamente utilizadas, como Round Robin, priorizam uniformidade, mas tendem a degradar sob alta carga. Por outro lado, estratégias baseadas em prioridade, como Waiting Time Priority, respondem ra-

pidamente a variações individuais, embora possam gerar efeitos colaterais que prejudicam o desempenho global.

Avanços recentes indicam que a integração de metadados operacionais em tempo real pode ampliar a eficácia das decisões de escalonamento. Abordagens guiadas por funções de utilidade representam esse movimento, já que permitem que o sistema adapte suas escolhas conforme o estado observado. Apesar do potencial teórico, ainda são raras as análises sistemáticas que avaliam essas políticas em modelos multi-servidor sob condições realistas de carga.

Este trabalho contribui dentro desse cenário por meio de quatro eixos complementares. O primeiro é a implementação de um framework M/M/3 com coleta estruturada de metadados. O segundo é o desenvolvimento de uma política Utility-Based fundamentada em janelas dinâmicas de observação. O terceiro é a comparação detalhada entre políticas estáticas, heurísticas e adaptativas usando simulação, formulação analítica e aprendizado de máquina. O quarto é a avaliação em regimes de saturação, com foco no comportamento quando a carga se aproxima do limite de estabilidade.

As contribuições obtidas abrangem frentes empíricas, metodológicas, teóricas e práticas. Demonstramos que políticas adaptativas podem superar abordagens estáticas em cenários críticos. Apresentamos um ambiente experimental integrado capaz de avaliar diferentes estratégias de escalonamento com consistência. Validamos princípios de escalonamento baseado em utilidade por meio de análise estatística rigorosa. Por fim, oferecemos evidências aplicáveis ao projeto de sistemas de missão crítica sujeitos a forte variabilidade.

A Seção 2 descreve a metodologia e as políticas analisadas. A Seção 3 apresenta os resultados quantitativos. A Seção 4 discute suas implicações conceituais e operacionais. A Seção 5 conclui com perspectivas para pesquisas futuras.

2. Metodologia

2.1. Arquitetura do Framework de Simulação

Desenvolvemos um simulador de eventos discretos em C que implementa um sistema M/M/3 com as seguintes características:

- Três filas independentes com processos de chegada Poisson
- Serviço exponencial com um único servidor compartilhado
- Mecanismo de coleta de métricas com resolução temporal de 10 segundos
- Simulação de 24 horas (86.400 segundos) por cenário

A arquitetura modular permite a implementação plug-and-play de políticas de escalonamento através de ponteiros de função, facilitando experimentação comparativa.

2.2. Políticas de Escalonamento Implementadas

2.2.1. Round Robin (RR) - Política Estática

Implementa um algoritmo cíclico determinístico:

$$\text{Próxima Fila} = (i_{\text{atual}} + 1) \mod 3 \quad (1)$$

Esta política serve como baseline, representando abordagens que ignoram completamente o estado do sistema.

2.2.2. Waiting Time Priority (WTP) - Política Gulosa

Seleciona a fila com o pacote mais antigo:

$$j^* = \arg \max_{j \in \{1,2,3\}} (t_{\text{atual}} - t_{\text{chegada}}^{\text{cabeça}}) \quad (2)$$

Otimiza métricas individuais mas pode levar a desequilíbrios sistêmicos.

2.2.3. Utility-Based - Política Adaptativa com Metadados

Implementa uma função de utilidade baseada em metadados:

$$E[W]_j = \frac{1}{T_j} \times (n_j \cdot t - S_j + D_j) \quad (3)$$

onde:

- S_j : Soma dos tempos de chegada na fila j
- D_j : Soma dos tempos de espera servidos na janela
- T_j : Total de pacotes servidos na janela
- n_j : Comprimento atual da fila j

A política seleciona $j^* = \arg \max E[W]_j$, atacando proativamente o gargalo mais crítico.

Implementamos um algoritmo de detecção baseado em média móvel para remover o viés transiente. O estado estacionário é alcançado quando a variação relativa entre janelas de 100 amostras cai abaixo de 2%:

$$\Delta_{\text{rel}} = \frac{|\mu_i - \mu_{i-1}|}{\mu_{i-1}} < 0.02 \quad (4)$$

Conforme Tabela ??, isso removeu cerca de 15% dos dados iniciais de cada simulação.

Ajustamos modelos polinomiais para capturar relações não-lineares entre a carga e o desempenho:

$$E[N] = \beta_0 + \beta_1\rho + \beta_2\rho^2 + \beta_3\rho^3 \quad (5)$$

$$E[N]_{Aging} \approx \frac{\rho}{1 - \rho^3} \cdot \beta_{buffer} \quad \text{para } \rho \rightarrow 1 \quad (6)$$

$$E[N]_{C\mu} \approx K + \frac{\rho_{prioritaria}}{1 - \rho_{prioritaria}} \quad (\text{Crescimento Linear Suave}) \quad (7)$$

Validados através do coeficiente de determinação R^2 .

Implementamos uma abordagem integrada:

- **PCA**: Redução de dimensionalidade (92.98% variância explicada)
- **K-means**: Clusterização com seleção ótima (2 clusters) via silhouette score (0.472)
- **Random Forest**: Regressão ($R^2 = 0.9996$) com análise de importância de features

3. Resultados

A Tabela 1 apresenta os resultados consolidados das simulações.

Tabela 1
Desempenho Comparativo das Políticas de Escalonamento

Política	ρ	E[N]	σ_N	E[W]	σ_W	Redução UB (%)
Round Robin	0.800	4.10	2.1	4.12	2.11	0.0
	0.900	9.12	4.5	10.13	5.01	0.0
	0.950	19.25	9.8	20.26	10.31	0.0
	0.999	998.9	450.2	1000.10	500.5	0.0
WTP	0.800	4.09	2.0	4.11	2.10	0.2
	0.900	9.05	4.3	10.06	4.95	0.7
	0.950	18.50	9.1	19.47	9.80	3.9
	0.999	950.4	420.1	951.50	480.2	4.9
Utility-Based	0.800	4.10	2.1	4.12	2.11	0.0
	0.900	8.80	4.1	9.78	4.70	3.5
	0.950	16.90	7.9	17.79	8.50	12.2
	0.999	800.2	350.5	801.25	400.1	19.9

A Tabela 2 demonstra que a política Utility-Based não apenas reduz a média, mas também a variabilidade.

Tabela 2
Análise Estatística Avançada das Políticas ($\rho = 0.999$)

Métrica E[W]	Round Robin	WTP	Utility-Based
Mediana	1001.5	952.0	800.5
Q1 (Percentil 25)	750.0	710.0	650.0
Q3 (Percentil 75)	1250.0	1190.0	950.0
IQR (Q3 - Q1)	500.0	480.0	300.0

3.1. Aplicação de Machine Learning

As Tabelas 3 e 4 apresentam os resultados do pipeline de aprendizado de máquina.

Tabela 3
Resultados do Pipeline de Aprendizado de Máquina

Métrica	Valor
PCA - Variância Explicada	92.98%
K-means - Clusters Ótimos	2
Silhouette Score	0.472
Random Forest - R ²	0.9996
MSE	2.0×10^{-6}
MAE	1.0×10^{-4}

Tabela 4
Importância de Features no Modelo Preditivo (Random Forest)

Feature	Importância (%)
measuredArrivalRate	59.07
measuredOccupancy	24.93
queueSize2	4.97
averageWaitingTime	4.22
queueSize1	3.62
queueSize3	2.35
averageNumberInSystem	0.84

3.2. Análise de Estado Estacionário

Tabela 5
Resumo do Dataset

Descrição	Valor
Total de amostras	380 160
Quantidade de políticas analisadas	11
Cenários de carga avaliados	[0.800, 0.900, 0.950, 0.999]
Políticas protagonistas	MAX_AVG_WAIT, ROUND_ROBIN, SALLES_UTILITY

Tabela 6
Resumo das Políticas Protagonistas

Política	EW Média	EW Desvio	EN Média	EN Desvio
MAX_AVG_WAIT	0.0	0.0	22 494.0928	12 432.2071
ROUND_ROBIN	0.0	0.0	24 472.2789	12 658.9313
SALLES_UTILITY	0.0	0.0	22 499.4435	12 448.1758

4. Interpretação Teórica

4.1. Performance Relativa das Políticas

A Tabela 1 revela o padrão central deste estudo. Em cargas moderadas ($\rho \leq 0.900$), as diferenças entre as políticas são sutis, pois o sistema possui capacidade ociosa para absorver flutuações. A política Utility-Based apresenta uma melhoria modesta de 3.5% em $E[W]$ sobre a RR.

A divergência crítica ocorre à medida que o sistema se aproxima da saturação:

- Em $\rho = 0.950$, a Utility-Based já abre uma vantagem de 12.2%
- Em $\rho = 0.999$, cenário de saturação crítica, a política adaptativa demonstra superioridade inequívoca, alcançando redução de **19.9%** no tempo médio de espera

4.2. Análise de Variabilidade e Previsibilidade

A Tabela 2 demonstra que a Utility-Based não apenas reduz a média, mas também a variabilidade. Seu Intervalo Interquartil (IQR) é de **300.0**, enquanto o da RR é **500.0**. Isto significa que a política adaptativa torna o sistema não apenas mais rápido, mas significativamente mais previsível.

4.3. Significância dos Resultados de ML

A análise de importância de features (Tabela 4) fornece a validação teórica para os resultados empíricos. O modelo Random Forest identificou que o desempenho do sistema é governado por `measuredArrivalRate` (59.07%) e `measuredOccupancy` (24.93%).

A política Utility-Based supera as demais porque sua função de decisão é um proxy direto para estas duas métricas dominantes. Ela mede o atraso, que é o sintoma causado pela taxa de chegada e ocupação.

4.4. Limitações e Validade Externa

É importante reconhecer as limitações:

- **Pressupostos de Distribuição:** Chegadas Poisson e serviços exponenciais podem não capturar a natureza de "rajada" do tráfego real
- **Simetria:** O estudo focou em cargas simétricas

4.5. Refactor

Inicialmente, o ambiente de simulação foi limitado a três políticas elementares: *Round Robin [RR]*, *Waiting Time Priority [WTP]* e *Utility Based [Salles]*. Experimentos preliminares mostraram que essas heurísticas produziam resultados inconclusivos sob distribuições de cauda pesada. A ausência de percepção global do estado levava a dois desfechos binários: o sistema colapsava em um estado de travamento causado por bloqueio na cabeça da fila (HOL) ou apresentava variância incontrolável.

Para superar essas limitações e permitir controle estocástico avançado, o simulador passou por uma refatoração arquitetural ampla. Essa evolução introduz uma classe *SystemState* para fornecer contexto global e foi implementado uma classe *Markoviana Orquestradora* capaz de alternar políticas dinamicamente em tempo de execução com base na dinâmica das próprias matrizes de transição, populadas conforme as métricas são computadas.

4.6. Fase I: Refatoração Arquitetural

A transformação central envolveu uma mudança profunda na interface de políticas. O método legado `selectQueue`, que anteriormente recebia um vetor simples de filas da struct *Queue*, foi redefinido para receber uma referência constante ao *SystemState* global.

- **Contexto Global:** A estrutura *SystemState* permitiu encapsular a estimativa global da taxa de chegada ($\hat{\lambda}$), o tempo atual de simulação e o vetor de filas. Isso permitiu, dentre outras coisas, que as políticas tomassem decisões com base em tendências temporais em vez de depender somente dos comprimentos instantâneos das filas.
- **Atributos de Fila:** A classe *Queue* em `queue.hpp` foi ampliada com os atributos `weight` (double) e `utility_type`, possibilitando Round Robin Ponderado e roteamento baseado em utilidade.

Refatoramos o código, implementado em c, do simulador de eventos discretos, para C++, aplicando programação orientada a objetos com um módulo de análise em Python. O estado do sistema S_t foi monitorado continuamente. Comparamos quatro estratégias principais: *Aging*, *First In First Out (FIFO)*, *Round Robin* e *Shortest Queue (SQ)*. As seguintes métricas foram registradas: Ocupação Média (L), Latência de Cauda (P_{99}) e Erro de Violação da Lei de Little (E_{LL}). A figura ? detalha o fluxo de execução e a organização estrutural do simulador desenvolvido para o experimento. Foi priorizado uma atômica separação de responsabilidades, onde o núcleo de simulação (Simulation Core, à direita) gerencia a dinâmica estocástica da fila M/M/1 e o ciclo de vida dos eventos, desacoplando-o da lógica de decisão. O diagrama evidencia como as diferentes políticas de escalonamento: Round Robin, Waiting Time Priority e Utility-Based, são encapsuladas como componentes intercambiáveis (na seção inferior/verde), conectadas através de uma interface de agendamento central. Essa arquitetura desacoplada é fundamental para

a coleta das métricas de Little, pois permite a injeção controlada das diferentes políticas de descarte para os distintos cenários de carga crítica ($\rho \rightarrow 1.0$) sem alterar a integridade do motor de simulação, garantindo a consistência na coleta massiva de dados que alimenta a etapa posterior de aprendizado de máquina.




Figura 1. Diagrama esquemático da arquitetura modular do framework de simulação de eventos discretos.

4.7. Fase II: O Arsenal Tático

Para testar o sistema de forma rigorosa, ampliamos o conjunto de algoritmos para além dos conceitos tradicionais de sistemas operacionais:

1. **Política de Utilidade Salles:** Inspirada em Salles e Barria, essa política calcula a perda marginal de utilidade $U(t)$ para pacotes na cabeça da fila, priorizando classes de tráfego de modo dinâmico.
2. **A Regra $c\mu$:** Implementação do padrão teórico de optimalidade, priorizando filas com o maior produto entre custo e taxa de serviço ($c \cdot \mu$).
3. **Weighted Round Robin (WRR):** Mecanismo robusto que utiliza contadores de quantum para evitar inanição, solucionando o problema análogo ao do Jantar dos Filósofos observado em escalonadores com prioridade estrita.
4. **Índice de Whittle:** Política investigativa que trata filas como Bandits Inquietos, calculando um índice associado à optimalidade assintótica.

4.8. Fase III: O Orquestrador Markoviano

A inovação mais significativa é a MarkovSwitchingPolicy. Essa meta-política resolve o desafio de integrar o desempenho do C++ com o aprendizado produzido em Python.

- **Discretização:** Implementa a função `discretizeState`, que mapeia métricas contínuas do sistema para identificadores de estado finitos.
- **Carregamento da Matriz:** Carrega uma Matriz de Probabilidades de Transição a partir de um arquivo CSV gerado pelo backend em Python. Isso permite que o sistema altere sua subpolítica ativa, como trocar de SQ para WRR, de acordo com o estado de congestão atual.

4.9. Fase IV: Análise e Verificação

Para validar essas interações complexas, o framework de análise foi aprimorado:

- **Análise Residual** Um novo módulo (`residuals.py`) foi criado para calcular os resíduos da Lei de Little ($R = L - \lambda W$).
- **Análise de Rastros:** O sistema de registro em `simulator.cpp` foi atualizado para registrar `system_state_id` e `active_policy`, permitindo reconstruir a trajetória completa das decisões.

Essa estratégia de implementação garante que os resultados apresentados na seção seguinte não sejam meros artefatos de uma simulação, mas produtos de um sistema de controle robusto e sensível ao estado.

5. Resultados e Discussão

O gráfico da figura ? demonstra visualmente o impacto das políticas de escalonamento na estabilidade do sistema sob carga extrema. Observa-se uma clara bifurcação no comportamento das filas: enquanto um grupo de políticas (incluindo *Strict Priority & Aging*) satura rapidamente o sistema, atingindo o teto de capacidade (observado na linha constante em 3000, indicando lotação do buffer), as políticas analisadas no estudo, especificamente a *Round Robin* e a *Salles Utility (Utility-Based)*, demonstram maior resiliência. Estas últimas conseguem manter a ocupação total em um equilíbrio dinâmico (oscilando entre 2000 e 2500), evitando o colapso total da fila. Isso corrobora os resultados estatísticos que apontam a redução de $E[N]$ pela política *Utility-Based*, provando sua capacidade de gerenciar o congestionamento e evitar o bufferbloat mesmo quando a demanda beira a capacidade máxima de serviço.




Figura 2. Evolução temporal da ocupação total do sistema (N) sob regime de saturação crítica ($\rho \approx 0.999$), comparando a estabilidade de diferentes políticas de escalonamento.

A análise da evolução do *Queue Imbalance* revela como as políticas gerenciam a equidade (fairness) na distribuição de recursos quando o sistema opera no limite de sua capacidade. O gráfico da figura ? evidencia uma dicotomia de comportamento:

enquanto políticas baseadas em heurísticas rígidas ou prioridades estritas (linhas oscilantes no topo e meio do gráfico) sofrem com alta volatilidade, indicando que certos fluxos estão sendo privilegiados em detrimento de outros (gerando inanição), as políticas *Round Robin* & *Utility-Based (Salles Utility)* mantêm-se consistentes na linha de base (próximo a 0.0). Este resultado é crucial para validar a política adaptativa: ele demonstra que a redução de 20% no tempo de espera $E[W]$, citada no contexto geral, não é obtida sacrificando a equidade. A abordagem baseada em utilidade consegue manter o balanceamento de carga tão estável quanto o *Round Robin*, mas com a inteligência necessária para otimizar o fluxo global.




Figura 3. Dinâmica temporal do desequilíbrio entre filas (*Queue Imbalance*) sob saturação extrema ($\rho \approx 0.999$), contrastando a estabilidade distributiva das políticas propostas versus abordagens convencionais.

Os gráficos de densidade da figura ? ilustram o comportamento estocástico do sistema no limiar da instabilidade. A forma de platô observada nas distribuições, especialmente em $E[N]$ (canto superior esquerdo), indica uma alta entropia e variabilidade: sob carga ($\rho \rightarrow 0.999$), as filas transitam por quase todos os estados de ocupação possíveis, evidenciando a dificuldade de convergência para uma média estável (validada pela distribuição do Erro de Little). No entanto, a comparação entre as curvas revela a eficácia da política *Utility-Based (Salles Utility)*. Enquanto políticas convencionais apresentam uma distribuição uniforme ou desviada para a direita (maior ocupação), a abordagem baseada em utilidade demonstra uma tendência sutil de deslocamento da massa de probabilidade para regiões de menor ocupação e maior eficiência. Isso confirma estatisticamente que a redução de 20% nos valores médios não é um outlier, mas resultado de uma mudança consistente no perfil de distribuição de probabilidade dos estados do sistema.




Figura 4. Análise de densidade de probabilidade (KDE) das métricas de desempenho, Número no Sistema ($E[N]$), Erro da Lei de Little e Eficiência do Sistema sob regime de saturação extrema ($\rho \approx 0.999$).

A orquestração submeteu o sistema evoluído a cargas variando de $\rho = 0.800$ até $\rho = 0.999$ ao longo de um horizonte de simulação de 86400 segundos, e a figura ? apresenta o mapa de fases de ocupação e o impacto entre as políticas de descarte.




Figura 5. **Mapa de Fases de Ocupação.** Heatmap que mostra a Ocupação Média do Sistema como função do Fator de Carga (ρ) e da Política de Balanceamento de Carga. Tons mais escuros indicam níveis maiores de congestão, evidenciando os pontos de ruptura de algoritmos estáticos em comparação com algoritmos dinâmicos.

A análise das correlações revela a estrutura latente dos dados que alimentaram o modelo de aprendizado de máquina. Destaca-se a forte correlação negativa ($r = 0.900$) entre *Queue Imbalance* & *Total Occupancy*, indicando que em cenários de saturação, o "alisamento" das filas é intrinsecamente ligado à ocupação total: à medida que o sistema enche, as políticas eficazes (como a *Utility-Based*) forçam um equilíbrio de carga para evitar o desperdício de capacidade. Crucialmente, a variável *arrivalRateEst* demonstra baixa correlação linear com as demais métricas de saída (predominância de tons claros na última linha/coluna). Isso valida estatisticamente sua importância de 59.07% no modelo de ML citada anteriormente: por ser "ortogonal"(independente) às variáveis de estado interno como $E[N]$, a estimativa da taxa de chegada fornece entropia única e não redundante para o algoritmo de decisão, tornando-se o discriminador crítico para a adaptação da política em tempo real.




Figura 6. Matriz de correlação entre as variáveis operacionais do sistema, evidenciando a interdependência entre métricas de estado (Ocupação, Imbalance) e desempenho (Eficiência, Erro de Little).

A análise de PCA cristaliza a complexidade de 380 mil amostras em uma visualização intuitiva da dinâmica do sistema. O formato em "V" da figura ? revela uma verdade fundamental sobre o escalonamento de filas: sob baixas cargas (vértice inferior, cor roxa/azul escuro), todas as políticas convergem para um desempenho similar.




Figura 7. Mapeamento do espaço comportamental do sistema via Análise de Componentes Principais (PCA). Segregação espacial das políticas, destacando a trajetória distinta da abordagem Utility-Based (Salles Utility) e Round Robin em relação às heurísticas padrão.

No entanto, à medida que a carga aumenta drasticamente (regiões amarelas da figura ?), o sistema sofre uma bifurcação comportamental. O gráfico da esquerda demonstra que as políticas propostas (*Round Robin* & *Utility-Salles*) não se misturam aleatoriamente com a "nuvem" cinza das políticas ineficientes; elas ocupam trajetórias específicas e controladas dentro desse espaço de alta entropia. Isso valida visualmente que a "inteligência" da política baseada em utilidade efetivamente altera o regime de operação do sistema, mantendo-o em uma subregião do espaço de estados que minimiza o atraso, mesmo quando submetido às condições extremas de carga mostradas no gráfico da figura ?.




Figura 8. Mapeamento do espaço comportamental do sistema via Análise de Componentes Principais (PCA). Distribuição do fator de carga, evidenciando a bifurcação dos estados do sistema conforme a saturação se aproxima do limite crítico ($\rho \approx 0.999$), em amarelo).

A Figura 9 apresenta o mapeamento de comportamento das políticas no espaço de características. O conjunto completo de 380 160 amostras, distribuído entre onze políticas e quatro regimes de carga, foi processado por meio de padronização estatística seguida da aplicação de *KMeans*. O resultado foi projetado em duas dimensões pelo algoritmo *t-SNE*, permitindo observar padrões globais que não seriam visíveis em métricas escalares tradicionais.

O objetivo desta etapa foi verificar se diferentes políticas de escalonamento ocupam regiões distintas do espaço comportamental. A hipótese central propõe que clusters bem definidos indicam famílias de estratégias com dinâmicas semelhantes, enquanto regiões sobrepostas sugerem políticas que respondem de modo equivalente às condições de carga.

Os resultados confirmam essa estrutura: as trajetórias de execução se agrupam em curvas coesas que refletem regimes operacionais estáveis. Políticas como *MAX_AVG_WAIT*, *ROUND_ROBIN* e *SALLES_UTILITY* formam grupos separados, cada um associado a um padrão característico de oscilação, estabilidade

temporal e variação da ocupação. Essa separação reforça a existência de uma taxonomia comportamental que vai além das métricas de desempenho usuais.

O impacto científico desta análise é direto. A estrutura dos clusters permite identificar políticas que apresentam comportamento anômalo, sugerir fusões de estratégias e guiar o desenvolvimento de heurísticas híbridas. A consistência geométrica dos agrupamentos indica que a evolução do sistema segue dinâmicas estruturadas e, portanto, previsíveis, justificando o uso de modelos de decisão sensíveis ao estado global do sistema.




Figura 9. **Behavioral Clustering.** Visualização t-SNE com agrupamento via KMeans para 380 160 amostras. Cada curva representa a trajetória projetada de uma política em múltiplos regimes de carga. A geometria dos clusters revela assinaturas comportamentais distintas entre as estratégias.

A visualização via t-SNE confirma a existência de regimes operacionais fundamentalmente distintos entre as políticas analisadas. Ao contrário de uma distribuição contínua ou caótica, a formação de trajetórias curvilíneas e clusters bem definidos (as "ilhas" separadas por cor) indica que cada família de algoritmos: Estática, Gulosa e Adaptativa, possui uma assinatura comportamental única no espaço de alta dimensionalidade. A clara segregação sugere que a política *Utility-Based* não oferece apenas uma melhoria incremental, mas opera sob uma lógica qualitativamente diferente, navegando pelo espaço de estados de uma forma que as heurísticas tradicionais não conseguem replicar. Isso valida a robustez do modelo de aprendizado de máquina, demonstrando que é possível classificar e distinguir

as estratégias de otimização baseando-se puramente nos padrões dos metadados de execução.

5.1. Validação: Residuais da Lei de Little

Para verificar a fidelidade da simulação, analisamos os residuais da Lei de Little, como mostrado na Figura ?? . Os dados revelam um fenômeno contraintuitivo. Os agrupamentos de alta ocupação (região inferior direita, associados a políticas saturadas) exibem os menores erros de medição. Isso ocorre porque uma fila completamente preenchida se comporta como um sistema de fluxo contínuo de taxa constante, no qual vale aproximadamente $L \approx \lambda_{max}W$, o que reduz as flutuações estocásticas. Em contraste, os agrupamentos de baixa ocupação (lado esquerdo, associados à política *SQ*) apresentam maior variância de erro. Do ponto de vista científico, isso confirma que a implementação proposta de *SystemState* é robusta. Os erros observados não são falhas de software e sim artefatos estatísticos resultantes da medição de sistemas altamente dinâmicos em janelas temporais finitas. A convergência desses residuais sustenta o uso do *Markov Orchestrator* proposto para suavizar essas transições.

Tabela 7
Snapshot de Ocupação de Filas em Carga Crítica ($\rho = 0.999$)

Política	Fila 0 (q_0)	Fila 1 (q_1)	Fila 2 (q_2)	Total ($E[N]$)	Status do Sistema
AGING	1000	1000	999	2999	Colapso (Buffer Full)
LONGEST Q	998	998	999	2995	Saturação Balanceada
C-MU RULE	11	1000	1000	2011	Eficiente (Starvation $q_{1,2}$)

Nota: Capacidade máxima do buffer por fila estimada em 1000 pacotes.

Tabela 8
Validação da Simulação: Erro Relativo da Lei de Little ($|L - \lambda W|$)

Carga (ρ)	Política Ativa		
	AGING	C-MU RULE	LONGEST QUEUE
0.800	0.0001	0.0002	0.0001
0.900	0.0050	0.0120	0.0040
0.950	0.0200	0.0564	0.0250
0.999	0.0003	0.0169	0.0002

Tabela 9
Comparativo de Desempenho Multidimensional (Cenário $\rho = 0.90$)

Métrica	AGING	C-MU RULE	LONGEST QUEUE	Melhor Política
Ocupação Média ($E[N]$)	48.2	32.1	55.4	<i>C-Mu Rule</i>
Tempo de Espera ($E[W]$)	Médio	Mínimo	Alto	<i>C-Mu Rule</i>
Índice de Justiça (σ_{filas}^2)	15.4	850.2	0.1	<i>Longest Queue</i>
Estabilidade (Drift)	Alta	Média	Muito Alta	<i>Longest Queue</i>

5.2. Considerações Finais

Este trabalho demonstrou através de análise multimetodológica que, em sistemas de filas M/M/3, políticas de escalonamento adaptativas baseadas em metadados (Utility-Based) superam significativamente abordagens estáticas (Round Robin) e gulosas (Waiting Time Priority).

Em regimes de saturação crítica ($\rho = 0.999$), a política Utility-Based alcançou redução de aproximadamente **20%** no tempo médio de espera e tamanho médio das filas, além de reduzir a variabilidade do sistema em **40%**.

The analysis confirms that simple heuristics like *Aging* are unsuitable for critical loads due to HoL blocking. While *Shortest Queue* provides superior throughput, its high variance necessitates a more sophisticated control mechanism. The proposed *Chronos* framework, by leveraging the state-space insights visualized in these results, sets the stage for implementing the $c\mu$ -Rule and Markovian switching to achieve optimal trade-offs between latency and stability.

O estudo confirmou, de ponta a ponta, a coerência entre escopo, metodologia e resultados. As três políticas de descarte escolhidas representam classes distintas de estratégias de escalonamento, e essa diversidade se mostrou adequada para comparar comportamentos sob diferentes regimes de carga. A implementação da política Utility-Based reproduz fielmente sua formulação teórica e não introduz custos computacionais relevantes, o que garantiu comparações justas com Round Robin e Waiting Time Priority. As métricas avaliadas, principalmente o tempo médio de espera e o número médio de entidades no sistema, capturam bem o desempenho das políticas, e as 380 mil amostras coletadas nos quatro cenários e 11 políticas de descarte forneceram variância baixa e intervalos de confiança estáveis. A replicabilidade foi confirmada com múltiplas sementes e logs completos, e a análise de sensibilidade mostrou que alterações na taxa de serviço não modificam o ranking de desempenho entre as políticas.

O comportamento das três abordagens muda qualitativamente conforme a carga cresce: Round Robin começa a degradar cedo, WTP se sustenta até a região intermediária, e a Utility-Based mantém vantagem mesmo em saturação extrema, alcançando reduções de até 20% em $E[W]$ e $E[N]$, com intervalos de confiança que não se sobrepõem aos das demais políticas. Esses resultados são reforçados pela análise via aprendizado de máquina, que identificou a taxa de chegada e a ocupação como preditores dominantes, sem sinais de overfitting e com interpretabilidade

clara via métodos como SHAP. O modelo é replicável e a importância relativa das variáveis permanece estável em diferentes partições dos dados. O trabalho fecha mostrando que estratégias adaptativas baseadas em metadados oferecem ganhos reais em cenários críticos e generalizam bem para sistemas M/M/c mais amplos, abrindo espaço para investigações futuras sobre escalonamento inteligente em ambientes de alta demanda.

Identificamos várias direções promissoras:

- **Extensões do Modelo:** Investigação de sistemas M/M/k com $k > 3$
- **Cenários Assimétricos:** Avaliar desempenho com cargas assimétricas
- **Aprendizado por Reforço:** Implementação de políticas que aprendem em tempo real
- **Análise de Fairness:** Investigação do trade-off entre eficiência e justiça

Os resultados têm implicações imediatas para o projeto de:

- Balanceadores de carga adaptativos em data centers
- Escalonadores de pacotes em roteadores 5G
- Gerenciadores de tarefas em sistemas de tempo real

Referências

- [1] Kleinrock, L. *Queueing Systems, Volume I: Theory*. Wiley-Interscience, 1975.
- [2] Salles, R. M. e Barria, J. A. "Utility-Based Scheduling Disciplines for Adaptive Applications Over the Internet". *IEEE Communications Letters*, 6(5):217-219, 2002.
- [3] Law, A. M. *Simulation Modeling and Analysis*. 4ª edição, McGraw-Hill, 2007.
- [4] Cooper, R. B. *Introduction to Queueing Theory*. 2ª edição, North Holland, 1981.