

Políticas de Escalonamento em Filas M/M/3: Uma Abordagem Multimetodológica

Rafael Passos DOMINGUES¹, Pedro Henrique Borges LUIZ¹

¹ *Instituto de Ciências Exatas, Universidade Federal de Alfenas (UNIFAL-MG), Brasil*
e-mail: rafael.domingues@sou.unifal-mg.edu.br, pedro.lui@sou.unifal-mg.edu.br

Abstract. Este artigo apresenta uma análise multimetodológica abrangente de políticas de escalonamento em sistemas de filas M/M/3, integrando simulação de eventos discretos, modelagem analítica e técnicas de aprendizado de máquina. Desenvolvemos um framework experimental que implementa três políticas distintas: Round Robin (estática), Waiting Time Priority (gulosa) e Utility-Based (adaptativa com metadados). As simulações foram conduzidas em quatro cenários de carga crítica ($\rho = 0.800, 0.900, 0.950, 0.999$) com 87.879 amostras coletadas. Os resultados demonstram que a política Utility-Based alcança reduções significativas de até 20% no tempo médio de espera ($E[W]$) e número médio no sistema ($E[N]$) em regimes de saturação extrema ($\rho = 0.999$). A análise de aprendizado de máquina identificou a taxa de chegada (59.07%) e ocupação (24.93%) como preditores dominantes, validando estatisticamente a abordagem baseada em metadados.

Key words: Análise de Desempenho, Simulação de Eventos Discretos, Sistemas de Filas M/M/3, Escalonamento Baseado em Utilidade, Metadados em Tempo Real, Aprendizado de Máquina Aplicado.

1. Introdução

1.1. Contexto Teórico e Relevância

A teoria de filas estocásticas constitui um alicerce matemático fundamental para a análise de sistemas de recursos compartilhados, com aplicações que abrangem desde arquiteturas de computação em nuvem até redes de telecomunicações 5G e sistemas de manufatura da Indústria 4.0. Enquanto modelos clássicos M/M/1 oferecem intuições teóricas valiosas, a complexidade dos sistemas contemporâneos demanda a investigação de configurações multi-servidor com disciplinas de escalonamento sofisticadas.

A transição para sistemas M/M/k introduz um problema de decisão fundamental: como alocar recursos de serviço limitados entre múltiplas filas competitivas. Esta problemática conecta-se a questões profundas na teoria da decisão sob incerteza e otimização de sistemas dinâmicos. Políticas convencionais como Round Robin (RR) implementam um princípio de justiça distributiva às custas da eficiência global, enquanto abordagens baseadas em prioridade, como Waiting Time

Priority (WTP), buscam otimizar métricas individuais podendo gerar ineficiências sistêmicas.

1.2. *Abordagem Baseada em Metadados e Estado da Arte*

A evolução recente na teoria de filas aponta para a utilização de informações contextuais em tempo real através de funções de utilidade. Esta abordagem representa uma transição paradigmática de políticas estáticas para sistemas adaptativos capazes de responder dinamicamente às condições operacionais. O conceito de "utilidade" como métrica para decisões de escalonamento foi introduzido na literatura, porém sua implementação prática em sistemas complexos permanece um desafio em aberto.

Neste contexto, nosso trabalho avança o estado da arte através de:

1. Implementação de um framework M/M/3 com coleta extensiva de metadados operacionais
2. Desenvolvimento de uma política Utility-Based com janelas de medição dinâmicas
3. Análise comparativa integrando simulação, modelagem analítica e aprendizado de máquina
4. Validação experimental em regimes de carga extrema ($\rho \rightarrow 1$)

1.3. *Contribuições Principais*

As contribuições deste trabalho são multifacetadas:

- **Empírica:** Demonstração quantitativa da superioridade de políticas adaptativas em cenários de alta carga
- **Metodológica:** Desenvolvimento de um framework experimental integrado para avaliação de políticas de escalonamento
- **Teórica:** Validação dos princípios de escalonamento baseado em utilidade através de análise estatística rigorosa
- **Prática:** Insights aplicáveis ao projeto de sistemas de missão crítica em ambientes de alta variabilidade

1.4. *Organização do Artigo*

O artigo estrutura-se da seguinte forma: A Seção 2 detalha a metodologia experimental, incluindo arquitetura do simulador, políticas implementadas e técnicas analíticas. A Seção 3 apresenta resultados quantitativos abrangentes com análise estatística detalhada. A Seção 4 discute implicações teóricas e práticas, enquanto a Seção 5 conclui com direções futuras.

2. Metodologia Experimental Integrada

2.1. Arquitetura do Framework de Simulação

Desenvolvemos um simulador de eventos discretos em C que implementa um sistema M/M/3 com as seguintes características:

- Três filas independentes com processos de chegada Poisson
- Serviço exponencial com um único servidor compartilhado
- Mecanismo de coleta de métricas com resolução temporal de 10 segundos
- Simulação de 24 horas (86.400 segundos) por cenário

A arquitetura modular permite a implementação plug-and-play de políticas de escalonamento através de ponteiros de função, facilitando experimentação comparativa.

2.2. Políticas de Escalonamento Implementadas

2.2.1. Round Robin (RR) - Política Estática

Implementa um algoritmo cíclico determinístico:

$$\text{Próxima Fila} = (i_{\text{atual}} + 1) \mod 3 \quad (1)$$

Esta política serve como baseline, representando abordagens que ignoram completamente o estado do sistema.

2.2.2. Waiting Time Priority (WTP) - Política Gulosa

Seleciona a fila com o pacote mais antigo:

$$j^* = \arg \max_{j \in \{1,2,3\}} (t_{\text{atual}} - t_{\text{chegada}}^{\text{cabeça}}) \quad (2)$$

Otimiza métricas individuais mas pode levar a desequilíbrios sistêmicos.

2.2.3. Utility-Based - Política Adaptativa com Metadados

Implementa uma função de utilidade baseada em metadados:

$$E[W]_j = \frac{1}{T_j} \times (n_j \cdot t - S_j + D_j) \quad (3)$$

onde:

- S_j : Soma dos tempos de chegada na fila j
- D_j : Soma dos tempos de espera servidos na janela
- T_j : Total de pacotes servidos na janela
- n_j : Comprimento atual da fila j

A política seleciona $j^* = \arg \max E[W]_j$, atacando proativamente o gargalo mais crítico.

2.3. Metodologias de Análise Cruzadas

2.3.1. Detecção de Estado Estacionário

Implementamos um algoritmo de detecção baseado em média móvel para remover o viés transiente. O estado estacionário é alcançado quando a variação relativa entre janelas de 100 amostras cai abaixo de 2%:

$$\Delta_{\text{rel}} = \frac{|\mu_i - \mu_{i-1}|}{\mu_{i-1}} < 0.02 \quad (4)$$

Conforme Tabela 5, isso removeu cerca de 15% dos dados iniciais de cada simulação.




Figura 1. Metodologia de detecção de estado estacionário (WTP, $\rho = 0.999$)

2.3.2. Modelagem Analítica Polinomial

Ajustamos modelos polinomiais para capturar relações não-lineares entre a carga e o desempenho:

$$E[N] = \beta_0 + \beta_1\rho + \beta_2\rho^2 + \beta_3\rho^3 \quad (5)$$

Validados através do coeficiente de determinação R^2 .

2.3.3. Pipeline de Aprendizado de Máquina

Implementamos uma abordagem integrada:

- **PCA**: Redução de dimensionalidade (92.98% variância explicada)
- **K-means**: Clusterização com seleção ótima (2 clusters) via silhouette score (0.472)
- **Random Forest**: Regressão ($R^2 = 0.9996$) com análise de importância de features

3. Resultados e Análise Quantitativa

3.1. Desempenho Comparativo das Políticas

A Tabela 1 apresenta os resultados consolidados das simulações.

Tabela 1
Desempenho Comparativo das Políticas de Escalonamento

Política	ρ	$E[N]$	σ_N	$E[W]$	σ_W	Redução UB (%)
Round Robin	0.800	4.10	2.1	4.12	2.11	0.0
	0.900	9.12	4.5	10.13	5.01	0.0
	0.950	19.25	9.8	20.26	10.31	0.0
	0.999	998.9	450.2	1000.10	500.5	0.0
WTP	0.800	4.09	2.0	4.11	2.10	0.2
	0.900	9.05	4.3	10.06	4.95	0.7
	0.950	18.50	9.1	19.47	9.80	3.9
	0.999	950.4	420.1	951.50	480.2	4.9
Utility-Based	0.800	4.10	2.1	4.12	2.11	0.0
	0.900	8.80	4.1	9.78	4.70	3.5
	0.950	16.90	7.9	17.79	8.50	12.2
	0.999	800.2	350.5	801.25	400.1	19.9

3.2. Análise Estatística Detalhada

A Tabela 2 demonstra que a política Utility-Based não apenas reduz a média, mas também a variabilidade.

Tabela 2
Análise Estatística Avançada das Políticas ($\rho = 0.999$)

Métrica $E[W]$	Round Robin	WTP	Utility-Based
Mediana	1001.5	952.0	800.5
Q1 (Percentil 25)	750.0	710.0	650.0
Q3 (Percentil 75)	1250.0	1190.0	950.0
IQR (Q3 - Q1)	500.0	480.0	300.0

3.3. Resultados de Aprendizado de Máquina

As Tabelas 3 e 4 apresentam os resultados do pipeline de aprendizado de máquina.

Tabela 3
Resultados do Pipeline de Aprendizado de Máquina

Métrica	Valor
PCA - Variância Explicada	92.98%
K-means - Clusters Ótimos	2
Silhouette Score	0.472
Random Forest - R ²	0.9996
MSE	2.0×10^{-6}
MAE	1.0×10^{-4}

Tabela 4
Importância de Features no Modelo Preditivo (Random Forest)

Feature	Importância (%)
measuredArrivalRate	59.07
measuredOccupancy	24.93
queueSize2	4.97
averageWaitingTime	4.22
queueSize1	3.62
queueSize3	2.35
averageNumberInSystem	0.84

3.4. Análise Gráfica Visual




Figura 2. Comparativo de $E[W]$ vs ρ




Figura 3. Análise comparativa do desempenho das políticas




Figura 4. Análise de Machine Learning

3.5. Análise de Estado Estacionário e Sensibilidade

Tabela 5
Análise de Estado Estacionário (Resumo)

Cenário	Total Amostras	Amostras Steady-State	Remoção (%)
RR $\rho = 0.800$	8642	7317	15.33
WTP $\rho = 0.900$	8642	7317	15.33
UB $\rho = 0.950$	8642	7317	15.33
RR $\rho = 0.999$	8642	7342	15.04

4. Discussão e Interpretação Teórica

4.1. Performance Relativa das Políticas

A Tabela 1 revela o padrão central deste estudo. Em cargas moderadas ($\rho \leq 0.900$), as diferenças entre as políticas são sutis, pois o sistema possui capacidade ociosa para absorver flutuações. A política Utility-Based apresenta uma melhoria modesta de 3.5% em $E[W]$ sobre a RR.

A divergência crítica ocorre à medida que o sistema se aproxima da saturação:

- Em $\rho = 0.950$, a Utility-Based já abre uma vantagem de 12.2%
- Em $\rho = 0.999$, cenário de saturação crítica, a política adaptativa demonstra superioridade inequívoca, alcançando redução de **19.9%** no tempo médio de espera

4.2. Análise de Variabilidade e Previsibilidade

A Tabela 2 demonstra que a Utility-Based não apenas reduz a média, mas também a variabilidade. Seu Intervalo Interquartil (IQR) é de **300.0**, enquanto o da RR é **500.0**. Isto significa que a política adaptativa torna o sistema não apenas mais rápido, mas significativamente mais previsível.

4.3. Significância dos Resultados de ML

A análise de importância de features (Tabela 4) fornece a validação teórica para os resultados empíricos. O modelo Random Forest identificou que o desempenho do sistema é governado por `measuredArrivalRate` (59.07%) e `measuredOccupancy` (24.93%).

A política Utility-Based supera as demais porque sua função de decisão é um proxy direto para estas duas métricas dominantes. Ela mede o atraso, que é o sintoma causado pela taxa de chegada e ocupação.

4.4. Limitações e Validade Externa

É importante reconhecer as limitações:

- **Pressupostos de Distribuição:** Chegadas Poisson e serviços exponenciais podem não capturar a natureza de "rajada" do tráfego real
- **Simetria:** O estudo focou em cargas simétricas

5. Conclusão e Trabalhos Futuros

5.1. Síntese de Contribuições

Este trabalho demonstrou através de análise multimetodológica que, em sistemas de filas M/M/3, políticas de escalonamento adaptativas baseadas em metadados (Utility-Based) superam significativamente abordagens estáticas (Round Robin) e gulosas (Waiting Time Priority).

Em regimes de saturação crítica ($\rho = 0.999$), a política Utility-Based alcançou redução de aproximadamente **20%** no tempo médio de espera e tamanho médio das filas, além de reduzir a variabilidade do sistema em **40%**.

5.2. Direções Futuras

Identificamos várias direções promissoras:

- **Extensões do Modelo:** Investigação de sistemas M/M/k com $k > 3$
- **Cenários Assimétricos:** Avaliar desempenho com cargas assimétricas
- **Aprendizado por Reforço:** Implementação de políticas que aprendem em tempo real
- **Análise de Fairness:** Investigação do trade-off entre eficiência e justiça

5.3. Implicações Práticas

Os resultados têm implicações imediatas para o projeto de:

- Balanceadores de carga adaptativos em data centers

- Escalonadores de pacotes em roteadores 5G
- Gerenciadores de tarefas em sistemas de tempo real

Referências

- [1] Kleinrock, L. *Queueing Systems, Volume I: Theory*. Wiley-Interscience, 1975.
- [2] Salles, R. M. e Barria, J. A. "Utility-Based Scheduling Disciplines for Adaptive Applications Over the Internet". *IEEE Communications Letters*, 6(5):217-219, 2002.
- [3] Law, A. M. *Simulation Modeling and Analysis*. 4ª edição, McGraw-Hill, 2007.
- [4] Cooper, R. B. *Introduction to Queueing Theory*. 2ª edição, North Holland, 1981.